

DARKOM.MA

Pipeline de Données Immobilières

Projet Data Engineering & Business Intelligence

1 508

Annonces

10

Villes

4

Dashboards BI

5

Dimensions DW

Python · Pandas · PostgreSQL · Power BI · SQLAlchemy

Contexte Métier

Le marché immobilier marocain a besoin d'analyse structurée

Darkom.ma

Plateforme immobilière marocaine proposant des annonces de vente et de location de biens immobiliers.

Les problèmes identifiés :

- Données incomplètes et valeurs manquantes
- Présence de doublons et d'incohérences
- Formats de données non standardisés
- Difficulté à garantir la qualité et la fiabilité des données

1 508

annonces collectées

10

villes analysées

5

types de biens

2023–2025

période couverte

Objectifs du Projet

Transformer des données brutes en valeur métier actionnable



Pipeline ETL

Automatiser l'ingestion,
le nettoyage et
le chargement des données



Data Warehouse

Construire un schéma
étoile optimisé pour
l'analyse dans
PostgreSQL



Data Quality

Détecter et corriger
les anomalies, doublons
et valeurs manquantes




Dashboards BI

Produire 4 dashboards
Power BI interactifs
pour les analystes

Architecture du Pipeline ETL

5 étapes orchestrées par main.py — du CSV au Dashboard



Exécution : *python main.py*

Staging Layer

Ingestion brute et traçabilité — `loads/load_staging.py`

Rôle du Staging

- **Chargement brut du CSV sans aucune transformation**
- **Tous les champs stockés en TEXT (sécurité source)**
- **Connexion PostgreSQL via psycopg2 + DictReader**
- **Création dynamique du schéma staging**
- **Log horodaté automatique dans staging.log**
- **Validation finale : COUNT(*) après chaque run**

Table : staging.annonces_raw

annonce_id	TEXT
date_publication	TEXT
titre	TEXT
ville	TEXT
quartier	TEXT
type_bien	TEXT
transaction	TEXT
prix	TEXT
surface	TEXT
nb_chambres	TEXT
nb_salles_bain	TEXT
etage	TEXT
annee_construction	TEXT
loaded_at	TIMESTAMP

Data Cleaning

Détecter, corriger, normaliser — scripts/clean.py



Déduplication

Suppression des lignes
dupliquées et des
enregistrements vides



Conversion
des types

date → datetime
prix → float
chambres → Int64



Valeurs
manquantes

quartier → 'Inconnu'
étage → 0
numériques →
médiane



Détection
Outliers

Méthode IQR sur
prix, surface,
chambres, sdb



Standard-
isation

strip() + title()
'Casa' → Casablanca
Normalisation textes

Résultat : données propres, typées et fiables → prêtes pour le Feature Engineering

Feature Engineering & Enrichissement

Créer de la valeur au-delà des données brutes

Variable créée	Formule / Logique	Valeur analytique
 prix_m2	$\text{prix} \div \text{surface}$	Comparaison normalisée entre biens de surfaces différentes
 age_bien	$2024 - \text{annee_construction}$	Indicateur de vétusté pour qualifier le patrimoine
 categorie_prix	$< 500K / < 1.5M / < 5M / \geq 5M$	Segmentation marché en 4 niveaux : Éco → Luxe
 categorie_surface	$< 80 / 80-150 / > 150 \text{ m}^2$	Classification Petit / Moyen / Grand
 annee_pub / mois_pub trimestre_pub	$\text{date_publication.dt.*}$	Dimensions temporelles pour l'analyse de tendances

Data Warehouse — Schéma Étoile

dim_temps

date_publication
annee · mois · trimestre

dim_categorie_prix

Éco · Moyen
Haut standing · Luxe

dim_bien

type_bien · etage
nb_chambres · categorie_surface

dim_localisation

ville
quartier

★ **fact_annonces**

Prix

Surface

prix_m2

age_bien

→ FK × 5 dims

dim_transaction

Vente / Location

✓ Jointures simples · Agrégations rapides · Dimensions lisibles nativement par Power BI · Évolutif (ajout de dimensions)

Chargement du Warehouse

loads/load_warehouse.py — SQLAlchemy + merge FK

1

Lecture

clean.annonces chargé via SQLAlchemy read_sql()

2

Extraction dims

drop_duplicates() pour chaque dimension

3

Insertion dims

to_sql(if_exists='append') → PostgreSQL génère les IDs

4

Récupération IDs

Relecture des tables pour obtenir les clés primaires

5

Merge FK

df.merge() pour associer les clés étrangères

6

Insertion faits

fact_annonces chargée avec toutes ses FK

Résultats du chargement

5

Tables
dimensions

1

Table
de faits

1 508

Lignes
fact_annonces

bi_schema

Schema
PostgreSaQL

Dashboards Power BI


4 pages connectées à bi_schema · Filtres et sliders interactifs

Page 1 — Vue Globale du Marché



- KPIs : 1K annonces, prix moyen 1,73M MAD
- Tétouan et Marrakech : 1er et 2e en volume
- Pic mensuel en novembre (135 annonces)
- Filtre année 2023 / 2025 via slider

Page 2 — Analyse des Prix




- Prix/m² moyen : 15 600 MAD
- Duplex (>4M) et Villas (>3M) = segment haut
- Tétouan : prix moyen le plus élevé (~2,5M)
- Filtres : catégorie prix + sliders

Dashboards Power BI (suite)


Analyse géographique et tendances temporelles

Page 3 — Analyse Géographique



- Agadir : 151 MAD/m² (1er) — Meknès : 49 MAD/m² (dernier)
- Table quartier → Zouagha (Fès) et Souissi (Rabat) en tête
- Filtres : ville · transaction · type bien · slider prix · m²

Page 4 — Analyse des Tendances



- Répartition par ville : chaque ville = 8–15% du marché
- Fès : prix moyen de 1 745 618 MAD
- Courbe d'évolution : comparaison inter-villes
- Filtres : catégorie prix, slider prix et prix / m²

Insights Métier & Conclusion

Ce que les données révèlent sur le marché immobilier marocain



Disparités géographiques fortes

Le prix/m² varie de 49 (Meknès) à 151 (Agadir) MAD — soit 3× d'écart entre les villes extrêmes



Segmentation du marché

Duplex et Villas dominent le haut de gamme. Les appartements représentent le volume le plus important



Saisonnalité détectée

Pic de publications en novembre — comportement saisonnier actionnable pour les agences et portails



Bilan technique

Pipeline ETL complet, modulaire, traçable. Architecture extensible vers scraping automatique et ML

Prochaines étapes : Scraper automatique · Apache Airflow · Coordonnées GPS · Modèle ML de prédiction des prix